



Прогнозирование потребительских расходов и обнаружение структурных изменений

Подготовили:
Петухова Мария
Неделько Мария
Разумовский Александр
Артемов Иван



Задача проекта

Цель — прогнозировать расходы и выявлять изменения потребительской активности

- Прогноз безналичных расходов по муниципальным образованиям и категориям потребления.
- Горизонты прогнозирования: 1, 3, 6 и 12 месяцев.
- Обнаружение отклонений от обычной динамики.
- Исследование возможности раннего предупреждения об экономических шоках.



Данные исследования

Основной источник — СберИндекс

- Период наблюдений: январь 2023 — декабрь 2024.
- Подготовленная обучающая таблица: 303 126 записей.
- Данные о расходах по территориям и категориям.
- Показатели доступности рынков и расстояния между муниципалитетами.
- Дополнительные данные: ключевая ставка и новостные тексты.



Подготовка данных и признаки

Модель учитывает историю расходов и динамику соседних территорий

- Временные признаки: месяц и год.
- Расходы за 1, 2 и 3 предыдущих месяца.
- Средние расходы за три прошлых месяца.
- Показатель доступности рынков.
- Взвешенные расходы до пяти ближайших муниципалитетов.

При поиске структурных изменений анализ начинается с четвёртого месяца, чтобы снизить влияние отсутствующих начальных лагов.



Учёт новостей и макроэкономики

Два подхода к анализу новостного фона

- Словарный анализ: оценка положительных и отрицательных слов.
- RuBERT: определение тональности с учётом контекста.



Реализованные подходы на примере LightGBM

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	MAE с NLP, руб.
1 месяц	400,76	414,30	855,18
3 месяца	543,13	567,48	919,52
6 месяцев	540,64	779,86	522,19
12 месяцев	800,69	836,19	772,62



Модели прогнозирования

В исследовании рассмотрены пять моделей

1. Prophet — Базовый прогноз с трендом и сезонностью.
2. LightGBM — Бустинг с временными, пространственными и внешними признаками.
3. CatBoost — Бустинг с поддержкой категориальных признаков.
4. Chronos — Предобученная модель временных рядов.
5. TimesFM — Фундаментальная модель на основе Transformer.



Проверка качества прогнозов

Временная кросс-валидация

- Обучающее окно последовательно расширяется.
- Для каждого горизонта используются три контрольных разбиения.
- При обучении учитываются только уже известные целевые значения.
- Итоговые метрики усредняются по трём разбиениям.

MAE — средняя абсолютная ошибка в рублях. Чем меньше, тем лучше.

R^2 — показатель качества объяснения вариации расходов.

Результаты прогнозирования Prophet

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R ² без новостей	R ² с новостями
1 месяц	1 274,71	861,62	0,9465	0,9848
3 месяца	484,46	798,34	0,9934	0,9875
6 месяцев	745,41	1 402,45	0,9877	0,9589
12 месяцев	907,07	1 399,35	0,9862	0,9591

Реализованные подходы на примере LightGBM

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	MAE с NLP, руб.
1 месяц	400,76	414,30	855,18
3 месяца	543,13	567,48	919,52
6 месяцев	540,64	779,86	522,19
12 месяцев	800,69	836,19	772,62



Результаты прогнозирования LightGBM

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R ² без новостей	R ² с новостями
1 месяц	399,52	697,76	0,9962	0,9885
3 месяца	540,67	713,85	0,9942	0,9917
6 месяцев	540,27	620,30	0,9928	0,9898
12 месяцев*	803,58	804,45	0,9840	0,9841



Результаты прогнозирования CatBoost

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R ² без новостей	R ² с новостями
1 месяц	870,61	456,48	0,9814	0,9941
3 месяца	928,40	623,78	0,9831	0,9902
6 месяцев	949,33	782,54	0,9735	0,9854
12 месяцев	855,74	936,33	0,9823	0,9794



Результаты прогнозирования Chronos

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R^2 с новостями
1 месяц	1 791,94	1 236,97	0,9687
3 месяца	2 513,96	1 905,77	0,9360
6 месяцев	2 708,87	2 453,24	0,8991
12 месяцев	2 694,35	2 455,59	0,8990



Результаты прогнозирования TimesFM

Горизонт прогнозирования	MAE, руб.
1 месяц	1 449,81
3 месяца	1 737,67
6 месяцев	2 052,37
12 месяцев	2 695,83



Лучшая модель

По результатам проведённых экспериментов наиболее эффективной моделью стала LightGBM без новостных признаков. Она продемонстрировала наименьшую ошибку MAE на горизонтах 1, 6 и 12 месяцев, а на горизонте 3 месяца лучший результат показала Prophet без новостей.

LightGBM без новостей



LightGBM с новостями





Влияние новостных признаков

Эффект новостей зависит от модели и горизонта

- CatBoost: MAE снизилась на 47,6%, 32,8% и 17,6% на горизонтах 1, 3 и 6 месяцев.
- Prophet: улучшение только на горизонте 1 месяц, снижение MAE на 32,4%.
- Chronos: MAE снизилась на всех четырёх горизонтах.
- LightGBM: добавление внешних признаков не снизило MAE.


Вывод: новостные признаки требуют отдельной проверки для каждой модели.



Обнаружение структурных изменений

Скрипт `compare_cpd.py` сопоставляет Prophet Changepoints, Ruptures (PELT с моделью l_1) и ML-Residuals. Первый метод определяет даты изменения тренда в модели Prophet; второй минимизирует сегментационную стоимость с добавлением штрафа за новую границу; третий обучает LightGBM и помечает месяцы, где абсолютная ошибка выше среднего остатка плюс установленная доля стандартного отклонения. В настройках архива пороги чувствительности заданы явно и могут изменяться.

Сравнение алгоритмов





Итоги

В ходе исследования были рассмотрены модели LightGBM, CatBoost, Prophet, Chronos и TimesFM для прогнозирования потребления на горизонтах 1, 3, 6 и 12 месяцев.

Наилучшие результаты на большинстве горизонтов продемонстрировала LightGBM, благодаря способности учитывать временные, пространственные и категориальные особенности данных. Добавление новостных признаков показало неоднозначные результаты, однако использование NLP на основе RuBERT позволило повысить точность LightGBM на горизонтах 6 и 12 месяцев.

Основным ограничением исследования является небольшая историческая выборка — 24 месяца, затрудняющая долгосрочное прогнозирование.

Таким образом, LightGBM выбрана в качестве основной модели, а дальнейшее улучшение прогнозов связано с расширением исторических данных и совершенствованием обработки новостей.



Спасибо за внимание!