

МЕТОДОЛОГИЧЕСКИЙ ОТЧЁТ

Прогнозирование потребительских расходов муниципальных образований и обнаружение структурных изменений

Проект хакатона Сбер • исследовательская версия

1. Постановка задачи

Цель работы — прогнозировать величину безналичных потребительских расходов в разрезе муниципальных образований (МО) и категорий потребления, а также выявлять отклонения от обычной динамики, которые могут свидетельствовать об экономических шоках. Для прогнозирования рассматриваются четыре горизонта: 1, 3, 6 и 12 месяцев. Вторая часть задачи требует не только ретроспективно находить разладки, но и оценивать возможность предупреждать о них заранее.

2. Описание и подготовка данных

2.1. Основные и дополнительные источники

Основной источник — файлы СберИндекса `consumption.parquet`, `market_access.parquet` и `connection.parquet`. Набор `consumption` содержит поля даты, идентификатора территории, категории и величины расходов (в коде поле `value`). Набор `market_access` содержит показатели доступности рынков; `connection` содержит расстояния между парами МО. Период, обозначенный в журналах обучения, — январь 2023 — декабрь 2024 года; подготовленная обучающая таблица содержит 303 126 записей. Таким образом, условие использования данных СберИндекса выполняется.

В качестве дополнительных внешних данных также используются `external_macro_data.csv` с ежемесячными значениями `cbr_key_rate` и текстами `news_text`, а также CSV, относящийся к изменению трат по категориям. Историческое значение ключевой ставки выступают как базовый маркер макроэкономических циклов.

2.2. Предобработка и формирование признаков

Скрипт `feature_engineering.py` сортирует наблюдения по МО, категории и месяцу, создаёт временные признаки `month` и `year`, а также лаги расходов за 1, 2 и 3 месяца и среднее значение расходов за три прошлых месяца. Из `market_access` добавляется статический пространственный индикатор. Для соседних муниципалитетов по `connection` выбираются до пяти ближайших связей, после чего рассчитывается взвешенный по обратному расстоянию средний лаг потребления соседей — `spatial_lag_1`.

Признаки объединяются в `train_features.parquet`. Первоначальный скрипт заполняет пропуски нулями и исключает строки с `value ≤ 0`. Это удобная базовая обработка, но она требует проверки: ноль может означать как отсутствие наблюдения, так и реальное нулевое потребление, а заполнение отсутствующих лагов нулями способно создавать искусственные сигналы в начале ряда. Мы учли этот математический артефакт: при поиске структурных сдвигов (Change Point Detection) алгоритм начинает оценку остатков только с 4-го месяца, что полностью нивелирует краевой эффект от заполнения нулями.

3. Интеграция новостных данных

3.1. Реализованные подходы

Для интеграции новостей мы рассмотрели 2 подхода.

Модуль `news_integration2.py` предназначен для интеграции макроэкономических и новостных данных в основной набор признаков. Он загружает данные из файла `external_macro_data.csv`, выполняет анализ тональности текстов на основе словаря положительных и отрицательных слов, формирует числовой индекс новостного настроения и объединяет полученные показатели с основной таблицей по месяцам. Такой подход позволяет учитывать общий информационный фон при прогнозировании потребления, однако ограничен использованием заранее заданного словаря и не всегда способен корректно определять контекст высказываний.

Модуль `news_integration_nlp.py` представляет собой расширенный вариант интеграции новостных данных с применением методов обработки естественного языка (NLP). Для анализа тональности используется RuBERT (Russian Bidirectional Encoder Representations from Transformers)

— нейросетевая модель на основе архитектуры Transformer, адаптированная для обработки русскоязычных текстов. Модель позволяет учитывать контекст высказываний и классифицировать новости по трём категориям: положительные, отрицательные и нейтральные. Полученные показатели агрегируются по временным периодам и включаются в набор признаков модели прогнозирования, что позволяет учитывать изменения новостного фона и его потенциальное влияние на потребление.

Дополнительно был усовершенствован механизм учёта макроэкономических факторов в модели LightGBM за счёт создания новых признаков, отражающих влияние изменений ключевой ставки и новостной тональности на потребление. Были добавлены показатели `cbr_impact` и `sentiment_impact`, учитывающие изменения макроэкономических факторов относительно среднего уровня потребления за последние три месяца. Также разработаны признаки `sentiment_elasticity` и `news_regional_impact`, позволяющие учитывать влияние новостного фона в зависимости от волатильности потребления и рыночной доступности муниципального образования. Это позволяет модели учитывать не только общие макроэкономические изменения, но и различия в их потенциальном воздействии на отдельные территории и товарные категории.

3.2. Реализованные подходы на примере LightGBM

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	MAE с NLP, руб.
1 месяц	400,76	414,30	855,18
3 месяца	543,13	567,48	919,52
6 месяцев	540,64	779,86	522,19

12 месяцев	800,69	836,19	772,62
---------------	--------	--------	--------

Результаты эксперимента показали, что модель LightGBM без новостных признаков обеспечивает наилучшую точность прогнозирования на горизонтах 1 и 3 месяца. Добавление новостей с использованием короткой функции не привело к улучшению результатов ни на одном из горизонтов, хотя на горизонтах 1 и 3 месяца ухудшение оказалось незначительным. Использование обычного подхода к интеграции новостей (длинная функция) также снизило точность модели на всех горизонтах, особенно на 1 и 3 месяца, где MAE увеличилась с 400,76 до 788,71 руб. и с 543,13 до 826,57 руб. соответственно.

При этом применение NLP позволило повысить точность прогнозирования на горизонтах 6 и 12 месяцев: MAE снизилась с 540,64 до 522,19 руб. и с 800,69 до 772,62 руб. соответственно. Однако на коротких горизонтах NLP показал худшие результаты по сравнению с базовой моделью.

Таким образом, для краткосрочного прогнозирования наиболее эффективна LightGBM без новостей, а для среднесрочного и долгосрочного — LightGBM с NLP-признаками. Полученные результаты свидетельствуют о том, что качество прогнозирования зависит не только от наличия новостных данных, но и от выбранного способа их обработки и интеграции.

4. Модели прогнозирования и сравнение результатов

4.1. Реализованные подходы

Для прогнозирования мы рассмотрели несколько современных фундаментальных моделей временных рядов, а именно LightGBM, Catboost, Chronos, TimesFM, Prophet.

Prophet - статистическая модель, предназначенная для прогнозирования отдельных временных рядов с учётом тренда и сезонности. Основными преимуществами являются простота использования и интерпретируемость, однако модель ограничена в выявлении сложных нелинейных зависимостей и не учитывает взаимосвязи между территориями без дополнительной настройки.

LightGBM - алгоритм градиентного бустинга, позволяющий эффективно обрабатывать большие объёмы данных и учитывать временные, пространственные и макроэкономические факторы. Его преимуществами являются высокая скорость обучения и способность выявлять сложные нелинейные зависимости, а недостатками — необходимость формирования дополнительных признаков и риск переобучения.

CatBoost - алгоритм градиентного бустинга, эффективно работающий с категориальными признаками, такими как идентификаторы муниципалитетов и товарные категории. Он позволяет учитывать сложные зависимости между факторами и снижать необходимость предварительного кодирования категорий, однако может требовать больше времени на обучение и тщательной настройки гиперпараметров.

Chronos - фундаментальная модель временных рядов, использующая предварительное обучение для прогнозирования новых последовательностей без дополнительного обучения (zero-shot). Её преимуществами являются возможность переноса знаний между временными рядами и отсутствие необходимости вручную создавать лаговые признаки, а недостатками — высокие вычислительные требования и ограниченная интерпретируемость.

TimesFM- фундаментальная модель на основе трансформерной архитектуры, предназначенная для прогнозирования временных рядов на различных горизонтах. Она способна выявлять сложные временные закономерности без дополнительного обучения, однако требует значительных вычислительных ресурсов и может недостаточно учитывать специфику отдельных территорий и внешние экономические факторы.

4.2. Кросс-валидация

Для оценки качества прогнозирования применялась временная кросс-валидация с расширяющимся обучающим окном (*Expanding Window Cross-Validation*). Для каждого горизонта прогнозирования (1, 3, 6 и 12 месяцев) формировались три последовательных валидационных фолда, соответствующих последним трём доступным датам наблюдений. На каждом этапе модель обучалась на исторических данных, причём в обучающую выборку включались только наблюдения, для которых целевое значение было известно до даты валидации. Такой подход позволяет учитывать временную структуру данных, снижать риск утечки информации из будущего и оценивать устойчивость модели на последовательных временных периодах. Итоговое качество определялось усреднением метрик MAE и R^2 по трём фолдам.

4.3. Ограничения текущей валидации

Ключевым ограничением исследования является прогнозирование на горизонте 12 месяцев при наличии всего 24 месяцев исторических данных. При формировании целевой переменной со сдвигом на 12 месяцев количество доступных наблюдений для обучения сокращается до 12 на каждый временной ряд. Таким образом, модель располагает лишь двумя годами исходной истории и фактически одним годовым циклом обучающих примеров, что недостаточно для надёжного выявления долгосрочных тенденций и устойчивых сезонных закономерностей. Особенно это ограничивает оценку влияния новостных и макроэкономических факторов, поскольку их воздействие на потребление может проявляться с задержкой. Следовательно, результаты прогнозирования на 12 месяцев следует интерпретировать с осторожностью, а для повышения их надёжности необходимо расширить историческую выборку как минимум до 3–5 лет.

4.4. Результаты Prophet

Эталоном для оценки следующих результатов является модель Prophet реализуемая в `baseline_prophet.py` и `train_prophet2.py`

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R² без новостей	R² с новостями
1 месяц	1 274,71	861,62	0,9465	0,9848
3 месяца	484,46	798,34	0,9934	0,9875
6 месяцев	745,41	1 402,45	0,9877	0,9589
12 месяцев	907,07	1 399,35	0,9862	0,9591

Результаты эксперимента показали, что добавление новостных и макроэкономических признаков в модель Prophet улучшило качество прогнозирования только на горизонте 1 месяц. Средняя абсолютная ошибка (MAE) снизилась с 1 274,71 до 861,62 руб. (на 32,4%), а коэффициент детерминации R² увеличился с 0,9465 до 0,9848.

Однако на более длительных горизонтах наблюдается ухудшение качества прогнозирования. На горизонте 3 месяца MAE увеличилась с 484,46 до 798,34 руб., на горизонте 6 месяцев — с 745,41 до 1 402,45 руб., а на горизонте 12 месяцев — с 907,07 до 1 399,35 руб. При этом значения R² также снизились, что свидетельствует об ухудшении точности модели.

Таким образом, в рамках проведённого эксперимента дополнительные новостные признаки не обеспечили устойчивого повышения качества прогнозирования Prophet. Возможными причинами являются ограниченный объём исторических данных (24 месяца), недостаточная информативность новостных показателей и сложность выявления их долгосрочного влияния на потребление.

4.5. Результаты LightGBM

Дополнительно для повышения точности прогнозирования был проведён автоматизированный подбор оптимальных гиперпараметров модели LightGBM с использованием библиотеки Optuna. В ходе оптимизации было предусмотрено 500 испытаний различных комбинаций параметров, включая скорость обучения, глубину деревьев, количество листьев и коэффициенты регуляризации. В качестве целевой функции использовалась минимизация среднего MAE по четырём горизонтам прогнозирования (1, 3, 6 и 12 месяцев) с применением временной кросс-валидации на трёх последовательных контрольных разбиениях. Общая продолжительность подбора гиперпараметров составила 39 часов. Полученные оптимальные параметры использовались для дальнейшего обучения и оценки модели LightGBM.

В журналах сохранены результаты трёх контрольных разбиений для каждого горизонта. Таблица показывает средние значения `train_horizons.py` и `train_horizons2.py`

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R ² без новостей	R ² с новостями
1 месяц	399,52	697,76	0,9962	0,9885
3 месяца	540,67	713,85	0,9942	0,9917
6 месяцев	540,27	620,30	0,9928	0,9898
12 месяцев*	803,58	804,45	0,9840	0,9841

Без новостей



С новостями



По результатам проведённых экспериментов установлено, что добавление новостных и макроэкономических признаков не привело к улучшению качества прогнозирования LightGBM. На горизонтах 1, 3 и 6 месяцев наблюдается увеличение средней абсолютной ошибки (MAE) и снижение коэффициента детерминации (R^2). Наиболее существенное ухудшение зафиксировано для горизонта 1 месяц, где MAE увеличилась с 399,52 до 697,76 руб. На горизонте 3 месяца ошибка выросла с 540,67 до 713,85 руб., а на горизонте 6 месяцев — с 540,27 до 620,30 руб.

На горизонте 12 месяцев различия между моделями оказались минимальными: MAE увеличилась всего на 0,87 руб., при этом R^2 незначительно вырос с 0,9840 до 0,9841. Это свидетельствует о практически сопоставимом качестве прогнозирования обеих моделей на данном горизонте.

4.6. Результаты CatBoost

Таблица показывает средние значения выполнения скриптов `train_catboost.py` и `train_catboost2.py`.

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R^2 без новостей	R^2 с новостями
1 месяц	870,61	456,48	0,9814	0,9941
3 месяца	928,40	623,78	0,9831	0,9902
6 месяцев	949,33	782,54	0,9735	0,9854
12 месяцев	855,74	936,33	0,9823	0,9794

Результаты эксперимента показали, что добавление новостных и макроэкономических признаков позволило повысить точность прогнозирования модели CatBoost на горизонтах 1, 3 и 6 месяцев. Наибольшее улучшение наблюдается на горизонте 1 месяц, где MAE снизилась на 47,6% (с 870,61 до 456,48 руб.), а R^2 увеличился с 0,9814 до 0,9941. На горизонтах 3 и 6 месяцев ошибка сократилась на 32,8% и 17,6% соответственно.

Однако на горизонте 12 месяцев добавление новостных признаков привело к ухудшению результатов: MAE увеличилась с 855,74 до 936,33 руб., а R^2 снизился с 0,9823 до 0,9794. Одной из возможных причин является ограниченная продолжительность исторических данных — 24 месяца, что затрудняет выявление устойчивых долгосрочных зависимостей.

Таким образом, использование новостных и макроэкономических факторов оказалось наиболее эффективным для краткосрочного прогнозирования CatBoost, особенно на горизонте 1–3 месяца. При этом для долгосрочных прогнозов требуется дальнейшее исследование значимости внешних признаков и расширение исторической выборки.

4.7. Результаты Chronos

Горизонт	MAE без новостей, руб.	MAE с новостями, руб.	R ² с новостями
1 месяц	1 791,94	1 236,97	0,9687
3 месяца	2 513,96	1 905,77	0,9360
6 месяцев	2 708,87	2 453,24	0,8991
12 месяцев	2 694,35	2 455,59	0,8990

Результаты эксперимента показали, что добавление новостных и макроэкономических признаков позволило повысить точность прогнозирования модели Chronos на всех рассматриваемых горизонтах. На горизонте 1 месяц средняя абсолютная ошибка (MAE) снизилась с 1 791,94 до 1 236,97 руб. (на 31,0%). На горизонтах 3, 6 и 12 месяцев ошибка сократилась на 24,2%, 9,4% и 8,9% соответственно.

Наибольшее улучшение наблюдается при краткосрочном прогнозировании, тогда как с увеличением горизонта положительный эффект от использования дополнительных признаков постепенно уменьшается. При этом коэффициент детерминации R² модели с новостями снижается с 0,9687 на горизонте 1 месяц до 0,8990 на горизонте 12 месяцев, что свидетельствует о снижении точности долгосрочных прогнозов.

Таким образом, использование новостных и макроэкономических факторов положительно повлияло на результаты Chronos в проведённом эксперименте, особенно на коротких горизонтах. Однако модель

по-прежнему уступает LightGBM по величине MAE. Возможными причинами являются ограниченный объём исторических данных (24 месяца) и недостаточная адаптация фундаментальной модели к специфике потребления отдельных муниципальных образований.

4.8. Результаты TimesFM

Горизонт прогнозирования	MAE, руб.
1 месяц	1 449,81
3 месяца	1 737,67
6 месяцев	2 052,37
12 месяцев	2 695,83

Результаты эксперимента показали, что модель TimesFM обеспечивает наибольшую точность прогнозирования на горизонте 1 месяц, где средняя абсолютная ошибка (MAE) составила 1 449,81 руб. С увеличением горизонта прогнозирования наблюдается последовательное ухудшение качества: на горизонте 3 месяца MAE увеличивается до 1 737,67 руб., на горизонте 6 месяцев — до 2 052,37 руб., а на горизонте 12 месяцев достигает 2 695,83 руб.

При сравнении с LightGBM модель TimesFM демонстрирует значительно более высокую ошибку на всех рассматриваемых горизонтах. Наиболее существенные различия наблюдаются при долгосрочном прогнозировании, где MAE модели TimesFM на горизонте 12 месяцев более чем в три раза превышает аналогичный показатель LightGBM (803,58 руб.).

Таким образом, применение TimesFM в режиме zero-shot не обеспечило преимуществ перед специализированной моделью LightGBM.

Возможными причинами являются ограниченный объём исторических данных (24 месяца), отсутствие дополнительной адаптации модели к специфике потребления отдельных муниципальных образований и ограниченный учёт пространственных и макроэкономических факторов. Полученные результаты свидетельствуют о том, что в рамках проведённого эксперимента LightGBM является более эффективным решением для прогнозирования потребления.

4.9. Лучшая модель

По результатам проведённых экспериментов наиболее эффективной моделью стала LightGBM без новостных признаков. Она продемонстрировала наименьшую ошибку MAE на горизонтах 1, 6 и 12 месяцев, а на горизонте 3 месяца лучший результат показала Prophet без новостей.

Основным преимуществом LightGBM является способность учитывать временные, пространственные и категориальные особенности потребления, выявлять сложные нелинейные зависимости и эффективно работать с большими объёмами данных. Дополнительно для повышения точности был проведён подбор гиперпараметров с помощью Optuna, занявший 39 часов.

Добавление новостных и макроэкономических признаков дало неоднозначные результаты: для CatBoost и Chronos наблюдалось улучшение точности, тогда как для LightGBM и Prophet преимущественно происходило ухудшение. При этом ограниченная история наблюдений (24 месяца) снижает надёжность оценки долгосрочных прогнозов.


Таким образом, для дальнейшего использования выбрана LightGBM, поскольку она показала наилучшие результаты на большинстве горизонтов и наиболее полно учитывает особенности исследуемых данных. Окончательное подтверждение её преимуществ требует сравнения всех моделей на одинаковых тестовых выборках.

5. Обнаружение структурных изменений

5.1. Три реализованных метода

Скрипт `compare_cpd.py` сопоставляет Prophet Changepoints, Ruptures (PELT с моделью l1) и ML-Residuals. Первый метод определяет даты изменения тренда в модели Prophet; второй минимизирует сегментационную стоимость с добавлением штрафа за новую границу; третий обучает LightGBM и помечает месяцы, где абсолютная ошибка выше среднего остатка плюс установленная доля стандартного отклонения. В настройках архива пороги чувствительности заданы явно и могут изменяться.

Для иллюстрации в скрипте выбирается муниципалитет с максимальной суммой расходов, а также категория «Все категории» при её наличии. Результаты отображаются на графике `cpd_comparison.png`. Такой визуальный пример полезен для демонстрации поведения алгоритмов, но сам по себе не устанавливает, какой метод точнее.



5.2. Ограничения сравнения и методика улучшения

В текущем `compare_cpd.py` LightGBM обучается на всём наборе данных, включая те же месяцы, по которым затем измеряются остатки. Полученные ошибки являются внутривыборочными; при таком подходе нельзя надёжно оценить качество реального обнаружения шоков. Кроме того, три метода не ранжированы по единой размеченной выборке событий, и для них пока не представлены Precision, Recall, F1 и задержка обнаружения. Поэтому качество методов на данный момент можно оценить только визуально, например ML-Residuals чаще попадает в одинаковые точки с другими моделями и хорошо отмечает точки скачков расходов.

Для корректной оценки требуется набор эталонных событий с датами их фактического возникновения. При ретроспективной проверке следует определять попадание обнаруженной точки в допустимое окно вокруг события и учитывать ложные тревоги. Для раннего предупреждения нужна отдельная постановка: на момент t рассчитывать риск сдвига в интервале $t+1 \dots t+k$, не используя значения расходов из этого будущего интервала. Качество такого прогноза оценивается долей обнаруженных событий, количеством ложных предупреждений и временем опережения.

Перспективное развитие — последовательный контроль ошибок out-of-sample прогноза (например, CUSUM или EWMA) и классификация риска будущего сдвига по лаговым признакам, новостям и динамике соседних муниципалитетов. Это предложения для следующего эксперимента, а не уже подтверждённые результаты.

6. Итоговые результаты и выводы

В ходе работы были исследованы и сравнены различные подходы к прогнозированию потребления на уровне муниципальных образований и товарных категорий. Для решения задачи использовались модели LightGBM, CatBoost, Prophet, Chronos и TimesFM. Прогнозирование выполнялось на горизонтах 1, 3, 6 и 12 месяцев, а оценка качества проводилась с использованием метрик MAE и R^2 .

По результатам экспериментов наиболее эффективной моделью стала LightGBM, продемонстрировавшая наименьшую ошибку на большинстве горизонтов прогнозирования. Её преимуществом является способность учитывать исторические значения потребления, сезонные закономерности, пространственные характеристики муниципальных образований и различия между товарными категориями. Для повышения точности был проведён автоматизированный подбор гиперпараметров с использованием Optuna, занявший 39 часов.

Отдельное внимание было уделено интеграции новостных и макроэкономических данных. Были рассмотрены словарный подход к анализу тональности новостей и метод на основе нейросетевой модели RuBERT. Эксперименты показали, что добавление новостных признаков не всегда улучшает качество прогнозирования. При этом использование

NLP-признаков позволило повысить точность LightGBM на горизонтах 6 и 12 месяцев, что указывает на потенциальную полезность учёта информационного фона при среднесрочном и долгосрочном прогнозировании.

Важным ограничением исследования стала небольшая продолжительность исторических данных — 24 месяца. Это затрудняет выявление устойчивых сезонных и долгосрочных закономерностей, особенно при прогнозировании на 12 месяцев. Дополнительным направлением совершенствования является расширение базы реальных новостных публикаций и повышение точности их территориальной привязки.

Таким образом, поставленная задача сравнительного исследования методов прогнозирования была решена, а в качестве основного алгоритма для дальнейшего развития системы выбрана LightGBM. Полученные результаты подтверждают перспективность использования градиентного бустинга для прогнозирования потребления с учётом пространственно-временных факторов. Дальнейшее развитие работы связано с увеличением исторической выборки, совершенствованием интеграции внешних данных и проверкой устойчивости моделей на новых временных периодах.